

OCR 적용 전후 비교

2026-10-06 · 텍스트 층이 없는 PDF 쪽을 OCR로 읽어 넣은 뒤 데이터·검색·답변이 어떻게 달라졌는지

비교 기준 · OCR 전 = 2026-10-06 10:49 실행(rag_gpt-4o-mini_fixed_questions_20261006_1049.csv), OCR 후 = 14:15 실행(..._1415.csv). 같은 모델(gpt-4o-mini, 온도 0)·같은 35문항·같은 검색 설정(fixed, 상위 10, 문서당 2, 공공 5 이상, 영어 번역 검색)입니다.
OCR 후 실행에는 OCR 말고도 답변 규칙 보정 3가지(4절)가 함께 들어갔습니다. 답변 수치 차이를 OCR 효과만으로 읽으면 안 됩니다.

1. 요약

데이터: 글자가 0자이던 쪽 154쪽 중 48쪽을 읽어 넣었습니다. 대부분(40쪽)이 신체활동 지침서이고, 이 문서의 글자 수가 15,198 → 36,079자(2.4배), fixed 조각이 63 → 164개가 되었습니다.
검색: 지침서가 검색 결과에 나오는 질문이 39개 중 11 → 18개로 늘었습니다. 기존 30문항의 기대 문서 적중은 그대로입니다(fixed 27, section_ctx 28, 바뀐 문항 0).
답변: 35문항 답변 중 11개의 검색 결과에 OCR 조각이 들어왔지만, OCR 조각을 인용한 답변은 0개입니다. 위반 0, 범위 판정 35/35, 되묻기 2/2로 점검 수치는 OCR 전과 같습니다.
주의: 새로 들어온 지침서 조각이 공공 자료 자리를 차지하면서 기대 근거 문서를 밀어낸 문항이 2개(18-27번) 생겼습니다.

2. 무엇을 했나

항목	내용
도구	Tesseract 5.5 (conda-forge), 한국어·영어 정밀 모델(tessdata_best). 정밀 모델은 tools/tessdata/에 두고 저장소에는 올리지 않음
대상	사용 문서 중 글자가 20자 미만인 쪽. 전부 그림인 스캔본(90% 이상 빈 쪽)과 완전 중복 문서는 제외
1차 거르기	200dpi·빠른 모델로 읽어 100자 미만이면 표지·간지로 보고 버림
2차 읽기	회색조 500dpi·정밀 모델, --psm 4, 띄어쓰기 보존
저장	data/ocr/<문서ID>/<쪽>.txt에 캐시 (다시 돌려도 읽지 않음), 쪽 텍스트에 "ocr": true 기록표에 OCR쪽 칸
정제·표시	깨진 머리말 줄과 글자 2개 이하 줄 삭제, OCR 조각에 꼬리표, 인용에 [OCR], 답변 규칙에 "단위·문맥이 맞지 않는 숫자는 쓰지 않음"

설정을 고른 이유 (지침서 49쪽, 핵심 수치 4개)


설정	공복혈당 250mg/dL	200-110mmHg 문장	"숨을 참아 체내 압력을"	띄어쓰기
300dpi 컬러 · 빠른 모델 · 기본 옵션	○	○	✗ "SS 참아 ... SSS"	✗ 대부분 붙음
300dpi 컬러 · 빠른 모델 · 띄어쓰기 보존	✗ "250000/0!_"	○ ("신체활동" 오타)	✗ "SS 참아"	○
300dpi 컬러 · 정밀 모델 · 띄어쓰기 보존	✗ "250070/0!-"	△ "혈압이"	✗ "체내 YAS"	○
300dpi 회색조 · 정밀 모델	○	△	✗ "체내 YAS"	○
400dpi 회색조 · 정밀 모델	○	○	○	○ ("신체활동" 1 곳)
500dpi 회색조 · 정밀 모델 (채택)	○	○	○	○

회색조가 숫자 오인식을, 높은 해상도가 단어 오인식을 줄였습니다. 정밀 읽기는 쪽당 약 30초라, 표지·간지를 먼저 거르는 1차 단계를 두었습니다.

3. 데이터 변화

문서	글자 0자 쪽	OCR로 넣은 쪽	버린 쪽 (표지·간지·빈 쪽)	글자 수 (전 → 후)
신체활동 지침서 (khepi-pa-004)	46	40 (본문 39 + 표지 1)	6	15,198 → 36,079
2026 비만 안내서 (khepi-ob-001)	19	1 (추진체계 도식)	18	63,950 → 64,359
2025 비만 안내서 (khepi-ob-002)	18	1	17	62,776 → 63,144
2025 신체활동 안내서 (khepi-pa-001)	13	2 (추진경과·체계)	11	70,797 → 71,663
2024 비만·신체활동 안내 (mohw-002-003)	16 · 15	1 · 2	15 · 13	61,321 → 61,743 · 69,918 → 70,715
2026 신체활동 안내 (mohw-007)	10	1	9	71,399 → 71,844
건강올임 · 어운완 · 비의료 가이드라인	8 · 4 · 5	0	17	변화 없음
합계 (사용 문서)	154	48	106	2,805,392 → 2,829,580 (+24,188)

신체활동 지침서(khepi-pa-004): 검색에 들어가는 양



청킹 방식	조각 수 (전 → 후)	OCR 조각	그중 지침서
fixed (기본)	9,661 → 9,774	121	101
fixed_ctx	9,661 → 9,774	121	101
section_ctx	5,409 → 5,466	86	71


- **문서 판정은 그대로:** 사용 93 / 제외 11. 스캔본(2025 신체활동 복지부판, 141쪽 전부 그림)은 개발원판과 내용이 같아 OCR하지 않고 제외를 유지했습니다.
- **꼬리표 변화 (section_ctx):** 공공 1,734 → 1,791, 노인 783 → 791, 청소년·소아 709 → 719, 임신 437 → 442. 지침서의 대상별 지침이 들어온 결과입니다.

OCR 품질

쪽 유형	예	상태
본문 문장	49쪽 만성질환별 고려사항, 47쪽 만성질환자 지침	잘 읽힘. "중강도 유산소 일주일에 150-300분", "근력 운동 주 2일 이상, 8~12회"가 그대로 나옴
숫자 오인식	47쪽	"300분 이상" → "3002 이상", "신체활동" → "MASS" 같은 오류가 일부 남음
표	29쪽 생활 예시 표, 65쪽 MET 표	칸 구조가 무너지고 잡음 기호가 섞임. 값은 읽히지만 어느 열의 값인지는 문맥으로 추측해야 함
표지·간지·사진	비만 안내서 31쪽(간지), 56쪽(홍보물 사진)	27자, 48자만 나와 1차에서 버림 (의도대로)

4. 검색 변화

검색·답변에서 지침서와 OCR 근거가 나온 질문 수



측정	OCR 전	OCR 후
기대 문서 적중, 현재 검색 설정 (30문항)	fixed 27 · fixed_ctx 27 · section_ctx 28	같음 (바뀐 문항 0)
지침서가 상위 10에 나온 질문 (평가 35 + 확인용 4)	11	18
"당뇨 회원이 운동 전 공복혈당이 얼마면 운동을 자제해야 하나요?"	지침서 없음	49쪽 검색됨 (250mg/dL 기준)
"고혈압 회원이 수축기 혈압이 높을 때 운동을 중단해야 하는 기준이 있나요?"	지침서 없음	여전히 없음 (같은 쪽인데도 순위 밖)

평가 문항 중 지침서 OCR 쪽이 새로 검색된 것: 3·4·6·13·18·27번(새로 등장), 1·5·7·9·32번(OCR 쪽으로 바뀌거나 추가).

5. 답변 변화

측정	기준	OCR 전 (10:49)	OCR 후 (14:15)
답변의 검색 결과가 같은 문항	35	22 같음 · 13 바뀜	
검색 결과에 지침서가 있는 답변	35	7	13
검색 결과에 OCR 조각이 있는 답변	35	0	11
OCR 조각을 인용한 답변	35	0	0
위반이 있는 문항	35	0	0
범위 판정 / 되묻기 / 확인 가능한 출처	35 / 2 / 32	35 / 2 / 32	35 / 2 / 32
기대 근거 문서를 인용	30	21	21 (읽음 18·27번, 얻음 2·3번)

평균 답변 길이 / 인용 번호 수	32	797자 / 3.4	811자 / 3.3
--------------------	----	------------	------------

- **밀려난 근거:** 지침서는 공공 자료라 "공공 5개 이상" 자리를 두고 다른 공공 자료와 경쟁합니다. 18번은 노인 고혈압 정보(kdca-023), 27번은 당뇨 운동요법(kdca-013)이 검색에서 빠지고 지침서 조각이 들어왔습니다. 검색 적중(문서 단위)은 다른 기대 문서로 유지됐지만 답변이 기대 문서를 인용하지 않게 됐습니다.
- **인용 0건의 의미:** 지금 평가셋은 지침서 내용을 직접 묻는 문항이 없어, 검색에 들어와도 답변은 논문·다른 공공 자료를 근거로 골랐습니다.

함께 들어간 답변 규칙 보정 (OCR 후 실행에서 생긴 문제를 고침)

중간 실행에서 본 문제	고친 방법
30번: 재작성해도 "고혈압 상태일 가능성이 높습니다"가 다시 나옴 (진단 표현 1/1)	재작성 뒤에도 남으면 그 문장을 코드로 삭제 (약 조절 문장도 함께)
22번: 판정기가 "폐경"을 범위 밖 질환으로 봐서 범위 판정 34/35	폐경·임신·노화 같은 생애 단계는 범위 밖 질환 목록에서 뺸
28번: 조건을 되묻지 않음 (되묻기 1/2, 실행마다 흔들림)	나이·성별·유형·경력이 하나도 없는 질문은 첫 문장에서 되묻도록 규칙 추가

6. 사례: OCR 쪽을 근거로 쓰는 질문

질문: "2형 당뇨 50대 남성 회원이 운동 전 공복혈당을 재 보니 260이 나왔대요. 오늘 운동해도 될까요?"

- 근거 목록에 **[10] 한국인을 위한 신체활동 지침서 개정판 49쪽 [OCR]**이 들어오고 인용도 됐습니다.
- 하지만 판단에는 지침서의 "공복혈당 250mg/dL 이상이면 자제" 대신 ACSM·ADA 권고의 "300mg/dL 이상이면 피함"을 썼고, 두 출처의 기준이 다르다는 점을 나눠 보여 주지 않았습니다(프롬프트의 "출처별로 나눠서" 규칙 미준수).

7. 한계와 다음 할 일

- **효과를 재는 문항이 없음:** 지침서 49쪽(만성질환 기준), 29~47쪽(대상별 지침), 65~67쪽(MET 표)을 근거로 하는 문항을 평가셋에 더해야 OCR이 답변을 바꾸는지 짚 수 있습니다.
- **공공 자료 자리 경쟁:** 지침서 조각이 다른 공공 자료를 밀어냅니다. 같은 문서 최대 개수를 공공 자료에서 더 줄이거나, 공공 자료 안에서 문서 다양성을 보장하는 방법을 실험할 수 있습니다.
- **OCR 오류:** 숫자 오인식과 표 구조 손실이 남아 [OCR] 인용은 원문 대조가 필요합니다. 표는 셀 단위 인식(표 전용 OCR)이 다음 후보입니다.
- **출처 간 기준 차이:** 지침서(250)와 학회 권고(300)처럼 기준이 다를 때 나눠 보여 주는지는 사람 채점에서 확인합니다.