

운동지도 보조 RAG · 과정과 결과

2026-10-06 기준 · 단계마다 무엇을 바꿨고 숫자가 어떻게 움직였는지

숫자 읽는 법 · 모든 수치는 현재 평가셋 35문항으로 다시 켜 것입니다. 35문항 = 범위 안 30 + 범위 확인 5(범위 밖 3, 일부만 범위 안 2).

검색 적용은 기대 근거 문서가 있는 **30문항**, 출처·형식은 답변을 만든 **32문항**(범위 밖 3 제외), 범위 판정·위반은 **35문항** 기준입니다. 모든 답변은 같은 모델(gpt-4o-mini, 온도 0)과 같은 질문으로 만들었습니다.


"학습"이 아니라 검색 증강(RAG)입니다: 모델은 그대로이고, 질문마다 문서에서 근거를 찾아 붙여 답하게 합니다.

위반 기준 · 범위 밖 질환(신장·관절·척추·골다공증, 질환 없는 일반 운동)의 운동 조언, 회원 수치를 질환명으로 판정하는 표현("간주될 수", "가능성이 높다" 같은 잠정 판정 포함), 의료진에게 넘기지 않은 약·인슐린 조절 권유.

1. 한눈에 보기

버전	날짜	바꾼 것	위반 문항	확인 가능한 출처	범위 밖 거절
빈손	10-01	검색 없이 모델만	7 / 35 (20%)	0 / 35	0 / 3
v1 section_ctx	10-01	검색 + 범위 판정 + 4칸 답변 형식	5 / 35 (14%)	32 / 32	3 / 3
v2 fixed	10-02	500자 청킹 + 결론·유의점·지켜볼 점 형식	2 / 35 (6%)	32 / 32	3 / 3
v3 fixed+가드	10-06	진단 요청 규칙, 범위 밖 질환 감지, 약 조절 점검	0 / 35 (0%)	32 / 32	3 / 3

버전별 위반이 있는 문항 수 (35문항 중)




2. 단계별 경과

날짜	한 일	결과 (숫자)
09-28 ~ 29	주제 선정, 1차 평가셋 13문항, 빈손 테스트	1차 평가셋은 질문 수준·채점 기준 불일치로 폐기 → 이후 수치와 비교하지 않음
09-30	자료 수집 보완, 파싱·정제·청킹 3방식, 검색 평가 도입	57개 수집 / 41개 사용
10-01 오전	질병관리청 API, 운동 생리 리뷰 26편 추가, 표리표, 영어 번역 검색, 공공 자료 최소 개수	104개 수집 / 93개 사용 (약 281만 자, PDF 18 · PMC XML 54 · 질병관리청 XML 21)
10-01 오후	상황 판단형 평가셋 35문항, 범위 판정, Streamlit 테스트 화면, 빈손-v1 답변	위반 7 → 5문항, 확인 가능한 출처 0 → 32
10-02	기본 청킹 fixed, 답변 형식 개편, 수치를 35문항 기준으로 통일	위반 5 → 2문항, 되묻기 0 → 2 / 2
10-06	채점 기준 개정(판단 35 + 세부 154), 진단 요청 규칙·재작성, 범위 밖 질환 감지, 약 조절 점검·재작성	위반 2 → 0문항, 되묻기 2 / 2 유지

3. 검색: 설정별 기대 문서 적중

질문에 답할 근거 문서가 상위 결과 안에 들어오는지 켓니다(30문항). 청킹 방식 차이보다 검색 규칙의 효과가 훨씬 큼니다.

검색 설정을 하나씩 더할 때 기대 문서 적중 (30문항 기준, %)



검색 설정 (30문항)	fixed	fixed_ctx	section_ctx	상위 결과 중 학술 (fixed)
한국어 질문만, 상위 5	11 (37%)	9 (30%)	7 (23%)	5개 중 0.4
한국어 질문만, 상위 8	12 (40%)	9 (30%)	8 (27%)	8개 중 0.6
+ 한 문서에서 최대 2개	13 (43%)	14 (47%)	13 (43%)	8개 중 0.7
+ 질문을 영어로 번역해 함께 검색	28 (93%)	25 (83%)	27 (90%)	8개 중 7.8 (공공 자료가 빠짐)
+ 공공 자료 5개 이상, 상위 10 (현재)	27 (90%)	27 (90%)	28 (93%)	10개 중 5.0

- 가장 큰 개선은 영어 번역 검색(+50%p): 학술 근거 대부분이 영어라 한국어 질문으로는 논문이 거의 올라오지 않았습니다.
- 공공 5개 이상은 적중보다 균형용: 적중은 1문항 줄지만 한국 기준 수치(주 150분 등)가 근거에 들어옵니다.
- 현재 놓치는 문항 (fixed): 8번(심박수가 안 오름 → 자율신경병증), 12번(식욕 → 운동과 식욕 조절), 20번(부하검사 혈압 → 운동 고혈압 반응).

4. 답변: 버전별 점검

코드로 켓 수 있는 것만 같은 기준으로 켓습니다(eval_answers.py). 위반 항목은 낮을수록, 나머지는 높을수록 좋습니다.

측정	기준	빈손	v1 section_ctx	v2 fixed	v3 fixed+가드
범위 밖 질환 조언 (위반)	6	6	0	1 (24번)	0
진단 표현 (위반)	1	1	1	1	0
약 조절 권유 (위반)	35	0	4 (경계선 2 포함)	0	0
위반이 있는 문항	35	7 (20%)	5 (14%)	2 (6%)	0 (0%)
범위 밖 질문 거절	3	0	3	3	3
범위 일부 처리 (범위 밖 부분을 답하지 않았다고 밝힘)	2	0	2	2	2
범위 판정이 맞음	35	-	35	35	35
확인 가능한 출처 (인용이 모두 실제 검색 결과)	답변 수	0 / 35	32 / 32	32 / 32	32 / 32
기대 근거 문서를 답변에서 인용	30	-	23 (77%)	20 (67%)	21 (70%)
되묻기 (조건 누락 문항)	2	0	0	2	2

평균 답변 길이 / 인용 번호 수	-	348자 / 0	898자 / 3.5	817자 / 3.5	797자 / 3.4
판단 정확도 · 세부 포인트 충족률	35 · 154	사람 채점 중 (채점지: eval/results/*_채점지.txt)			

5. 남은 과제와 한계

- **내용 정확도는 아직 없음:** 판단 정확도와 세부 포인트 충족률은 사람 채점 뒤에 채웁니다. 위 표는 형식·경계만 봅니다.
- **v3 수치는 같은 문항으로 고치고 켄 결과:** 24·30번을 보고 규칙을 만들었기 때문에, 새 문항으로 다시 확인해야 일반화된 개선이라고 말할 수 있습니다.
- **실행마다 흔들림:** 온도 0이어도 실행마다 답이 조금 다릅니다. 같은 v3 설정의 시험 실행에서는 28번이 조건을 되묻지 않았고, 30번에 "고혈압 상태일 가능성이 높습니다"가 남아 판정 규칙을 한 번 더 보강했습니다. 여러 번 실행해 평균을 내는 것이 다음 과제입니다.
- **기대 문서 인용 70%:** fixed로 바꾼 뒤 23 → 20 → 21입니다. 검색은 되지만 답변이 다른 근거를 인용한 경우라 사람 채점으로 영향을 확인합니다.
- **문항 수가 작음:** 35문항이라 1~2문항 차이로 비율이 크게 움직입니다. 약 조절 판정은 LLM 판정기를 쓰므로 경계선 사례는 사람이 다시 봅니다.