

운동지도 보조 RAG · 진행 경과

2026-10-02 기준 · 마지막 커밋 408fdde · 파싱 · 정제 · 청킹을 중심으로

숫자 읽는 법 · 이 문서의 모든 수치는 현재 평가셋 35문항으로 다시 짤 것입니다. 35문항 = 범위 안 30 + 범위 확인 5(범위 밖 3, 일부만 범위 안 2).
검색 적중은 기대 근거 문서가 있는 **30문항**, 답변 점검은 답변을 만드는 **32문항**(범위 밖 3 제외), 범위 판정은 **35문항** 기준입니다. 모든 검색은 상위 10개 · 한 문서 최대 2개 · 공공 5개 이상 · 영어 번역 검색(현재 설정)입니다.


1. 한눈에 보기

당뇨·비만·고혈압 회원의 질환 유형·연령·성별·운동 경력이 조합된 상황을 물으면, 무엇을 주의해야 하는지 논문·공공 자료를 근거로 판단해 주는 도구입니다. 문서 104개를 모아 93개를 쓰고, 이를 9,661개 조각(fixed)으로 잘라 검색합니다.


항목	값	항목	값
수집 / 사용 문서	104 / 93개	사용 글자 수	약 281만 자
형식 (사용 기준)	PDF 18 · PMC XML 54 · 질병관리청 XML 21	검색용 조각 (기본 fixed)	9,661개, 평균 406자
평가셋	35문항 (상황 판단형)	검색 적중 (기대 문서)	30문항 중 27 (90%)
범위 판정	35문항 중 35 (100%)	답변 내용 정확도	사람 채점 중 (채점 포인트 183개)

문서 104개 → 검색용 조각 9,661개(fixed) → 질문마다 근거 10개로 판단

데이터 준비 (한 번만)



질문할 때마다



범위 밖(근골격계 질환 등)이면 검색·답변 없이 안내만 합니다. 답변 채점은 임상 내용이라 사람이 합니다.

2. 경과

날짜	한 일	결과
09-28 ~ 09-29	주제 선정, 1차 평가셋 13문항, 빈손 테스트(LLM만)	1차 평가셋은 10-01 폐기(질문 수준·채점 기준 불일치)
09-30	수집 보완(이미지로 받아진 PDF, PMC 검색 오류, 한국건강증진개발원 게시판), 파싱·정제·청킹 3방식, 검색 평가, RAG 첫 답변	57개 수집 / 41개 사용
10-01 오전	질병관리청 Open API 수집, 목표 재정리 → 운동 생리 리뷰 26편 추가·기전 논문 5편 복원, 포리표·영어 번역 검색·공공 자료 최소 개수	104개 수집 / 93개 사용, 검색 규칙 추가로 기대 문서 적중 27% → 93% (section_ctx, 현재 30문항으로 다시 짤)
10-01 오후	평가셋 30문항·채점 포인트, Streamlit 테스트 화면, 범위 판정(당뇨·비만·고혈압 밖은 답하지 않음), 답변 형식·질문을 상황 판단형으로	평가셋 35문항, 커밋 408fdde
10-02	기본 청킹을 fixed로 변경(주의사항 우선), 답변 형식 변경(결론 문단 → 지도할 때 유의할 점 → 회원에게서 지켜볼 점 → 근거), 모든 수치를 35문항으로 다시 측정	RAG 답변 35문항 재생성

3. 문서 고르기 (문서 단위 정제)

조각을 다듬기 전에 문서 자체를 먼저 거릅니다. 판정은 collect.py가 정해진 기준으로 자동으로 하고, 사람 판단은 판정_수동 칸에 적으면 우선합니다.

수집 104개 → 사용 93개 (제외 11개)



작은 칸 오른쪽부터: 주제 무관 4 · 중복 3 · 초록만 3 · 스캔본 1

같은 문서가 두 곳에 있으면 코드로 받은 쪽을 남깁니다(다시 돌려도 똑같이 받을 수 있어서).

제외 사유	알아내는 방법	수	사례
완전 중복	파일 지문(SHA256)이 같음	2	복지부 수동본 = 개발원 자료실 파일 (신체활동 지침서, 2025 비만 안내서)
내용 중복	본문 10글자 조각이 98% 이상 같음	1	2026 비만 안내서: 파일은 다르고 본문은 100% 같음
스캔본	90% 이상의 쪽에서 글자가 안 나옴	1	2025 신체활동 안내서 복지부판 (141쪽 전부 0자) → 개발원판으로 대체
초록만 제공	본문 1,500자 미만	3	ADA 2016 성명서, 정정문 2편
주제 무관	사람이 검토	4	인구 역학 조사, 지침 준수율 조사, 편지

4. 파싱: 형식별로 글자 꺼내기

문서 형식이 셋이라 꺼내는 방법도 셋입니다. 결과는 모두 "위치 단위(쪽 또는 섹션) + 본문"으로 맞춰서, 다음 단계(정제·청킹)가 형식을 신경 쓰지 않게 했습니다.

형식이 다른 세 종류를 '위치 단위(쪽 또는 섹션) + 본문'으로 통일



5. 정제: 잡음을 걷어내고 위치를 지키기

PDF에서 꺼낸 글자는 사람이 보는 모양과 다릅니다. 쪽마다 같은 머리말이 끼고, 줄이 단어 중간에서 끊기고, 표는 칸마다 한 줄이 됩니다. chunk.py가 아래 순서로 정리합니다.

정제 전·후: 고강도 간헐적 운동과 당뇨병 (J Korean Diabetes 2024), PDF 2쪽

정제 전 (PDF에서 꺼낸 그대로)

~~www.diabetes.or.kr~~ ← 반복 머리말

225 ← 인쇄 쪽 번호

조윤정 외 ← 반복 머리말

서론

...만성 질환으로, 심혈

관계 질환과 다양한 합병증의 위험을...

← 단어 중간 줄바꿈

→

정제 후

[위치: 225쪽] ← PDF 2번째 장 = 인쇄 225쪽

서론

...만성 질환으로, 심혈관계 질환과 다양한

합병증의 위험을...

머리말 2줄 제거, 쪽 번호는 근거 표시용으로 따로 기록,
'심혈 / 관계'를 '심혈관계'로 이어 붙임


빨강 = 지운 것, 노랑 = 위치 정보로 옮긴 것, 파랑 = 고친 것

단계	규칙	왜	규모·사례
① 기호 정리	제어문자 제거, 특수 글머리표(»)를 "-"로	검색·표시 오류 방지	신체활동 지침서의 보이지 않는 제어문자(BEL)
② 머리말·꼬리말 제거	쪽 위·아래 3줄에 있는 같은 문장이 글자 있는 쪽의 25% 이상에서 반복되면 삭제	모든 조각에 같은 문장이 끼면 검색이 흐려짐	반복 문장 30종 제거. 지침서 제목은 35쪽 중 33쪽에 반복. 25%로 둔 것은 "한다." 같은 우연한 반복을 지우지 않기 위해
③ 인쇄 쪽 번호 찾기	쪽 위·아래 숫자로 PDF 순서와 인쇄 쪽의 차이를 문서마다 계산	근거는 원문에 인쇄된 쪽으로 보여줘야 확인 가능	12개 문서에 차이. 학회지는 PDF 2번째 장 = 225쪽, 2025 신체활동 안내서는 20번째 장 = 16쪽
④ 끊긴 줄 잇기	원문 줄 끝에 빈칸이 있으면 띄어 쓰고, 한글 단어 중간에서 끊겼으면 붙임. 20자 미만 줄은 표 칸으로 보고 띄어 씀	문장이 이어져야 뜻으로 검색됨	"심혈 / 관계" → "심혈관계". 표 칸은 "운동 유형 운동 강도"로(처음엔 "운동 유형운동 강도"로 붙는 오류가 있어 고침)
⑤ 각주 구분	"숫자" 모양이라도 번호가 15보다 크면 제목이 아니라 각주로 봄	각주가 섹션 이름이 되는 오류 방지	"44) 건강검진결과상담 매뉴얼"
⑥ 범위 밖 섹션 제외 (논문)	감사의 글·이해상충·연구비, 약물치료·입원·예방접종 장 등 제외	약 조절은 다루지 않는 도구라 검색을 흐림	13편에서 24개 섹션 제외. 2025 당뇨병 진료지침(66만 자)은 조각 1,014 → 726개

6. 청킹: 검색 단위로 자르기

문서를 통째로 검색하면 140쪽짜리 안에서 전체가 답으로 나옵니다. 그래서 질문 하나에 답할 만한 크기로 자르고, 어느 방식이 나은지 미리 알 수 없어 세 방식을 만들어 비교했습니다.

같은 두 쪽(105·106쪽)을 세 방식으로 자르면



방식	자르는 법	조각 수	평균 길이	특징
fixed (기본)	쪽 안에서 500자씩, 앞 조각과 100자 겹침. 가능하면 문장·빈칸에서 끊음	9,661	406자	쪽을 넘지 않아 근거 쪽이 정확. 표·제목이 잘릴 수 있음
fixed_ctx	fixed와 같게 자르고 앞에 [문서명 쪽] 한 줄	9,661	511자	"비만 안내서"처럼 문서 이름으로 묻는 질문과 잘 연결
section_ctx	"가.", "1)", "## 섹션" 같은 제목에서 끊고 문단을 900자까지 묶음 + [문서명 섹션]	5,409	706자	제목과 내용이 한 조각. 673개 조각은 여러 쪽에 걸쳐 실제 글자가 있는 쪽 목록을 따로 기록


세 방식 비교

측정	fixed	fixed_ctx	section_ctx
한국어 질문만, 상위 5개 · 기대 문서 적중 (30문항)	11 (37%)	9 (30%)	7 (23%)
현재 검색 설정 · 기대 문서 적중 (30문항)	27 (90%)	27 (90%)	28 (93%)
넘겨주는 근거 분량 (32문항 평균)	4,110자	4,066자	6,139자
근거 1,000자당 주의 문장 수 (32문항 평균)	1.54	1.21	1.12
빈도·강도·시간이 한 조각에 다 있는 경우 (32문항, 질문당)	0.78	1.12	1.28

- 주의사항은 **fixed**가 자세함: 주의 문장은 문서 곳곳에 한두 문장씩 흩어져 있어, 짧은 조각일수록 그 문장 위주로 검색되고 비율도 section_ctx의 1.4배입니다.
- 운동 처방은 **section_ctx**가 나옴: 처방은 제목 아래 표·목록으로 묶여 있어서, 제목 기준으로 자르면 빈도·강도·시간이 한 조각에 함께 들어옵니다(약 1.6배).
- 결정 (10-02): 적중률 차이는 1문항뿐이라 검색만으로는 우열이 없습니다. 답변을 읽어 보니 fixed가 주의사항을 더 꼼꼼하게 담아, 주의사항을 우선해 기본값을 fixed로 바꿨습니다. 운동 처방 쪽 손실은 두 방식을 반씩 섞어 가져오는 실험으로 확인할 예정입니다.

7. 꼬리표, 질문 처리와 검색

질문 한 개가 처리되는 순서 (rag_test.run)



판정기가 혈압·혈당·비만 같은 단어가 있는 질문을 범위 밖으로 막지 않도록 안전장치를 두었습니다(진단·약 질문은 답변 단계의 경계 규칙으로 처리).

조각은 OpenAI 임베딩(text-embedding-3-small)으로 저장해 뜻이 가까운 조각을 찾습니다. 학술 자료 대부분이 영어라 검색 규칙을 더했습니다.

검색 설정 (30문항)	fixed	section_ctx	상위 결과 중 학술 자료 (fixed)
한국어 질문만, 상위 8	12 (40%)	8 (27%)	8개 중 0.6
+ 한 문서에서 최대 2개	13 (43%)	13 (43%)	8개 중 0.7
+ 질문을 영어로 번역해 함께 검색	28 (93%)	27 (90%)	8개 중 7.8 (공공 자료가 거의 빠짐)
+ 공공 자료 5개 이상, 상위 10 (현재)	27 (90%)	28 (93%)	10개 중 5.0

조각마다 붙인 꼬리표

꼬리표	어디서 읽 나	분포 (section_ctx 5,409조각)
자료 종류	출처	학술 3,675 · 공공 1,734
질환	문서 제목	당뇨 2,160 · 비만 1,266 · 고혈압 1,179 (겹침 허용)
대상	조각 본문	노인 783 · 청소년·소아 709 · 여성 607 · 2형 591 · 임신 437 · 1형 337 · 남성 309 · 이차성 고혈압 10 · 원발성 고혈압 9

8. 평가와 남은 과제

평가셋 유형	문항	예
계획 판단	20	50대 고혈압 숙련자 남성이 데드리프트 중량을 더 올리고 싶대요. 어떻게 생각해?
운동 시 문제 / 운동 반응 기전	3 / 3	인슐린 쓰는 60대 여성이 운동 중 식은땀·손 떨림, 조금 쉬었다 계속하겠대요
조건 누락 / 경계	2 / 2	"당뇨 회원 오늘 고강도로 해도 돼요?", 혈압약 중단·진단 요청
범위 밖 / 범위 일부	3 / 2	허리 디스크 회원 데드리프트, 비만 + 무릎 관절염

답변 점검

측정	기준 문항	section_ctx (10-01)	fixed (10-02, 현재)
범위 판정이 맞음	35	34 (97%) · 24번을 일부만 범위 안으로	35 (100%)
정해진 답변 형식을 지킴	32	32 (100%)	32 (100%)
인용 번호가 모두 실제 검색 결과에 있음	32	32 (100%)	32 (100%)

기대 근거 문서를 답변에서 실제로 인용	30	23 (77%)	20 (67%)
답변 내용 정확도 (채점 포인트 충족 수)	35 (포인트 183개)	사람 채점 중 → 채점지 합계로 "충족 포인트 / 183"과 문항별 충족률을 냅니다	

- **자동으로 재는 것과 사람이 재는 것:** 위 네 줄은 코드로 짭니다. 내용이 맞는지(채점 포인트 충족)는 임상 내용이 라 자동 채점하지 않고 사람이 채점지로 매깁니다. 빈손(LLM만)과 RAG를 같은 포인트로 매겨 비교합니다.
- **fixed로 바꾸며 생긴 손실:** 기대 문서를 검색하고도 답변에서 인용하지 않은 문항이 늘었습니다(23 → 20). 주의사항 품질과 함께 사람 채점으로 확인할 부분입니다.
- **검색이 놓친 경우:** fixed는 8·12·20번, section_ctx는 6·8번. 질문에 위험·기전 이름이 없을 때 놓칩니다("심박수가 안 오름" → 자율신경병증, "식욕만 늘어" → 운동과 식욕 조절, "부하검사에서 혈압이 과하게 오름" → 운동 고혈압 반응 논문). 위험을 검색어에 넣어 넓히는 실험이 다음 후보입니다.
- **정제의 남은 한계:** 신체활동 지침서 홀수 쪽(49쪽 포함)은 글자가 그림이라 OCR이 필요하고, 표는 어느 값이 어느 열인지가 사라집니다.
- **답변에서 본 오류:** 인용 없는 설명이 섞이거나 약 조절에 가까운 표현이 나오는 경우가 있어, 사람 검토 메모로 모아 오답노트로 정리합니다.