

당뇨·비만·고혈압 회원 운동지도 보조 RAG

개발 보고서 · 2026-10-06 · 데이터 구축부터 검색·답변 설계, 평가, 동결까지

요약

트레이너가 "50대 고혈압 숙련자 남성 회원이 데드리프트 중량을 더 올리고 싶대요. 지도할 때 주의해야 할 점은?"처럼 회원의 질환·연령·성별·운동 경력이 겹친 상황을 물으면, 논문·학회 지침을 먼저, 공공 자료를 보충 근거로 찾아 주의할 점을 답하는 검색 증강 생성(RAG) 도구를 만들었다. 문서 104개를 수집해 93개(약 283만 자)를 쓰고, 9,774개 조각으로 나눠 검색한다. 같은 모델(gpt-4o-mini, 온도 0)로 검색 없이 답한 "빈손"과 비교하면, 개발용 평가셋 35문항에서 위반(진단·약 조절·범위 밖 조언)이 있는 문항이 9개(26%) → 0개, 확인 가능한 출처가 0% → 100%, 범위 밖·일부만 범위 안 질문 처리 0 / 5 → 5 / 5, 조건 되물기 0 / 2 → 2 / 2가 됐고, 기대 근거 문서 검색 적중은 30문항 중 29개(97%)다. 답변 내용의 정확도(핵심 판단 35개, 세부 포인트 154개)는 임상 내용이라 사람이 채점하며 아직 진행 중이다. 시스템은 동결했고, 처음 보는 문항으로 한 번만 재는 홀드아웃 평가 절차를 마련했다.

수치 읽는 법 · 평가셋 35문항 = 범위 안 30 + 범위 확인 5(범위 밖 3, 일부만 범위 안 2). 검색 적중은 기대 근거 문서가 정해진 30문항, 출처·형식은 답변을 만든 32문항(범위 밖 3 제외), 범위 판정·위반은 35문항이 기준이다. 2026-10-06에 질문 문장을 "어떻게 생각해?"에서 "지도할 때 주의해야 할 점은?"으로 바꿨다. 5·6장의 개발 단계 비교는 예전 문장, 8장의 최종 결과는 바꾼 문장 기준이며 두 기준을 섞어 비교하지 않는다.

1. 목적과 범위

같은 고혈압이라도 50대 숙련자 남성의 중량과 70대 초보 여성의 근력운동은 주의할 점이 다르다. 지침은 질환별로 나뉘어 있어, 연령·성별·질환 유형·경력이 겹친 회원 앞에서 어느 기준을 어떻게 적용할지 트레이너가 판단하기 어렵다. 이 도구는 그 조합에서 무엇을 주의해야 하는지, 하려는 것을 해도 되는지를 근거와 함께 판단해 준다.

항목	내용
사용자	헬스장·PT 트레이너, 생활체육지도자
질환	당뇨(1형·2형·임신당뇨와 합병증), 비만, 고혈압(원발성·이차성·임신 고혈압)
조합 조건	연령(청소년·성인·노인), 성별(폐경 포함), 질환 유형, 운동 경력, 임신
근거 우선순위	학술(논문·학회 지침)을 먼저, 공공(보건복지부·한국건강증진개발원·질병관리청)은 한국 기준 수치 보충
하지 않는 것	진단, 약·인슐린 조절, 범위 밖 질환(근골격계·암·심장·폐·신장 등)과 질환 없는 일반 운동 질문 → 의료기관·전문가 안내

시스템 구성

데이터 준비 (한 번)

수집 104개 (논문·지침·공공)	선별 93개 사용, 11개 제외	파싱 PDF·PMC XML·질병관리청 XML	정제 + OCR 머리말·줄바꿈·쪽 번호, 그림 글자 48쪽	청킹 fixed 500자, 9,774조각	꼬리표·임베딩 학술/공공·질환·대상
-----------------------	----------------------	-----------------------------	-------------------------------------	---------------------------	------------------------

질문할 때마다

질문 회원 조건 + 상황	범위 판정 LLM + 단어 규칙	검색 번역 + 공공 5(문서당 1)	답변 결론→유의점→지켜볼 점→근거	가드 진단·약 조절·되물기	출력 근거 번호[OCR] 표시
------------------	----------------------	------------------------	-----------------------	-------------------	---------------------

주황: 위반을 막는 단계. 범위 밖이면 검색·답변 없이 안내만, 일부만 범위 안이면 범위 밖 질환을 뺀 질문으로 답하고 안내 문구를 붙임. 진단 요청·약 조절 문장은 다시 쓰게 하고, 그래도 남으면 그 문장을 지움.

2. 데이터 구축

출처 목록(sources.csv)과 수집 프로그램(collect.py)으로 다시 돌려도 같은 문서를 받도록 했다. 사이트의 robots.txt를 확인하고 같은 사이트에는 3초 간격으로 요청했으며, 자동 수집이 금지된 보건복지부 게시판 자료만 직접

받아 등록했다.

출처	받은 방법	수집 / 사용
PubMed Central: 국내 학회지 진료지침·연구 (당뇨·고혈압·비만)	공식 API(E-utilities)에 논문 번호 지정, 본문 XML	33 / 27
PubMed Central: 운동 생리·대상별 운동 리뷰	같은 방법 (대상별·기전별 빈칸을 채우려고 추가)	26 / 26
ADA 2016 신체활동 성명서	같은 방법	1 / 0
국내 학술지 PDF (J Korean Diabetes, 대한의사협회지, 대한비만학회 지침 요약)	PDF 주소로 직접	9 / 9
질병관리청 국가건강정보포털	승인받은 Open API, 건강정보 XML (키는 저장소 밖에 보관)	21 / 21
한국건강증진개발원 자료실 (비만·신체활동 안내서, 신체활동 지침서 등)	게시판 화면의 첨부 정보를 읽어 PDF	6 / 6
보건복지부 사업안내 (수동)	브라우저로 받아 등록	7 / 3
비의료 건강관리서비스 가이드라인 (경계 판단용)	직접 받아 등록	1 / 1
합계	사용 형식: PMC XML 54 · PDF 18 · 질병관리청 XML 21	104 / 93 (약 283만 자)

선별 기준 (제외 11개)

제외 사유	판정 방법	개수
완전 중복	파일 지문(SHA256)이 같음. 코드로 받은 쪽을 남김	2
내용 중복	본문 10글자 조각이 98% 이상 같음	1
스캔본	90% 이상의 쪽에서 글자가 나오지 않음 (같은 내용의 개발원판이 있어 OCR 대신 제외)	1
초록만 제공	본문이 1,500자 미만	3
주제 무관	기초의학·역학·편지 (사람 판정, 기록표의 판정_수동 칸)	4

연도판끼리 60% 이상 겹치는 안내서(예: 2025·2026 비만 사업안내서 83%)는 해마다 바뀐 기준을 비교할 수 있어 둘 다 남기고 "유사"로만 표시했다. 원본 파일은 저작권 때문에 저장소에 올리지 않고 문서별 기록표(data/manifest.csv)만 공개한다.

3. 전처리: 파싱·정제·OCR·청킹

파싱과 정제

PDF는 쪽별로, 논문·건강정보 XML은 섹션별로 글자를 꺼냈다. 쪽 번호를 지켜야 근거를 "문서 · 쪽"으로 보여 줄 수 있어서다.

정제 규칙	방법	이유
머리말·꼬리말 제거	쪽 위·아래 3줄에 같은 문장이 글자 있는 쪽의 25% 이상에서 반복되면 삭제 (30종 제거)	모든 조각에 같은 문장이 끼면 검색이 흐려짐
끊긴 줄 잇기	원문 줄 끝 빈칸이면 띄어 쓰고, 한글 단어 중간이면 붙임. 20자 미만 줄은 표 칸으로 보고 띄움	"심혈 / 관계" → "심혈관계"
인쇄 쪽 번호	쪽 위·아래 숫자 줄로 PDF 순서와 인쇄 쪽의 차이를 문서마다 계산	PDF 20번째 장 = 인쇄 16쪽 같은 차이
각주 구분	"15)"보다 큰 번호의 "숫자)"는 제목이 아닌 각주로 봄	각주가 제목으로 잡히던 오류
범위 밖 장 제외	진료지침의 약물치료·입원·예방접종 장, 논문의 감사의 글·이해상충	약 조절은 이 도구의 범위 밖



OCR (텍스트 층이 없는 쪽)

신체활동 지침서는 홀수 쪽의 글자가 도형으로 그려져 0자로 나왔고, 그 안에 만성질환별 고려사항(49쪽: 수축기 200·이완기 110 mmHg 이상이면 격렬한 활동 자제, 공복혈당 250 mg/dL 이상이면 자제)과 대상별 지침이 있었다. Tesseract 5.5(한국어·영어 정밀 모델)로 읽었다.

- **설정:** 300dpi 컬러에서는 "250mg/dL"을 "250070/0!"로 잘못 읽었다. 회색조로 바꾸자 숫자 오인식이, 500dpi로 높이자 단어 오인식이 사라져 회색조 500dpi·띄어쓰기 보존으로 정했다.
- **거르기:** 200dpi로 먼저 읽어 100자 미만이면 표지·간지로 보고 버린다. 사용 문서의 0자 쪽 154쪽 중 48쪽(지침서 40, 사업안내서 도식 8)을 넣고 106쪽을 버렸다. 썸네일로 직접 분류한 결과와 쪽 번호까지 일치했다.
- **표시:** 숫자 오인식("300분" → "3002")과 표 구조 손실이 남아, OCR 조각은 인용에 [OCR]을 붙이고 답변 규칙에 "단위·문맥이 맞지 않는 숫자는 쓰지 않음"을 넣었다.


청킹 (세 방식 비교)

방식	자르는 법	조각 수	평균 길이	근거 1,000자당 주의 문장	빈도·강도·시간이 한 조각에
fixed (채택)	쪽 안에서 500자, 100자 겹침	9,774	406자	1.50	0.72
fixed_ctx	fixed + 앞에 [문서명 쪽]	9,774	511자	1.17	1.03
section_ctx	제목·문단 경계, 900자까지 묶음 + 머리말	5,466	707자	1.09	1.22

주의 문장은 문서 곳곳에 한두 문장씩 흩어져 있어 짧은 조각일수록 그 문장 위주로 검색된다(fixed가 section_ctx의 1.4배). 운동 처방(빈도·강도·시간)은 제목 아래 묶여 있어 section_ctx가 낫다(1.7배). 이 도구의 목적이 주의사항이라 fixed를 택했다. 조각마다 자료 종류(학술 3,675 · 공공 1,791, section_ctx 기준), 질환, 대상(노인·청소년·여성·임신·1형·2형 등) 꼬리표를 달고, text-embedding-3-small로 임베딩한다.

4. 검색 설계

검색 설정별 기대 문서 적중 (fixed, 30문항, %)



검색 설정 (fixed, 기대 근거 문서가 있는 30 문항)	적중	무엇을 해결했나
한국어 질문만, 상위 5 / 상위 8	11 / 12	기준선. 학술 근거 대부분이 영어라 한국어 질문으로는 논문이 거의 안 나옴 (상위 8 중 학술 0.6개)
+ 한 문서에서 최대 2개	13	같은 문서의 비슷한 조각이 상위를 독차지하던 문제
+ 질문을 영어로 번역해 함께 검색 (두 점수 중 높은 쪽)	28	가장 큰 개선(+15문항). 다만 상위가 논문으로만 채워져 한국 기준 수치가 빠짐
+ 공공 자료 5개 이상 (상위 10)	27	논문·공공 자료를 반씩 가져옴 (적중 1 줄지만 "주 150분" 같은 한국 기준이 근거에 들어옴)

아래는 질문 문장을 "지도할 때 주의해야 할 점은?"으로 바꾼 뒤		
문장 변경 직후 (설정 같음)	24	모든 질문 끝의 같은 요청이 검색 뜻을 흐림
+ 질문 끝 공통 요청을 빼고 검색	27	상황 부분만 검색
+ 공공 뭇은 한 문서당 1개 (동결)	29	OCR로 늘어난 지침서 조각이 다른 공공 자료를 밀어내던 문제
(시험) 번역에 상황이 암시하는 위험·기전 이름 덧붙이기	26	"심박수가 안 오름" → 자율신경병증처럼 이름이 없는 질문을 노렸으나 오히려 감소 → 채택 안 함


세 청킹 방식의 적중 차이는 1~3문항이라 검색만으로는 우열이 없었다. 정답이 문서 단위라 같은 문서 안에서 어느 조각을 찾았는지는 구분하지 못하며, 기대 문서를 정한 사람이 논문도 고른 것이라 적중률이 실제보다 높게 나왔을 수 있다.

5. 답변 생성 설계

구성	내용
답변 형식	결론 문단(해도 되는지와 핵심 유의점, 조건이 빠졌으면 되물기) → 지도할 때 유의할 점 → 회원에게서 지켜볼 점 (보이는 신호 → 의심되는 문제 → 이유 → 대처) → 근거 (번호별 문서·쪽)
근거 규칙	[근거]에 있는 내용만, 항목마다 [번호], 학술 먼저, 출처마다 기준이 다르면 나눠서("[1]은 250, [2]는 300", 더 보수적인 쪽으로 지도), 다른 대상의 근거면 밝힘, [OCR] 숫자 주의
범위 판정	LLM 판정(범위 안 / 일부만 / 범위 밖) + 범위 단어(당뇨·혈압 등)가 있으면 범위 밖으로 막지 않음 + 범위 밖 질환명(신장·관절염·디스크 등)이 있으면 "일부만"으로 + 폐경·임신 같은 생애 단계는 질환으로 보지 않음. 일부만 범위 안이면 범위 밖 질환을 뺀 질문으로 검색·답변하고 안내 문구를 코드가 붙임
진단 요청 가드	"무슨 병인지 진단해" 같은 요청이면 회원 판정 금지 규칙을 더함. "~에 해당", "~일 가능성이 높다" 같은 판정 문장이 남으면 다시 쓰게 하고, 그래도 남으면 그 문장을 삭제
약 조절 가드	약·인술린 조절 문장 후보를 정규식으로 찾고 판정기(LLM)로 "의료진에게 넘기지 않은 권유"인지 확인 → 다시 쓰기 → 남으면 삭제
조건 되물기	나이·성별·질환 유형·경력이 하나도 없는 질문은 첫 문장에서 필요한 조건을 묻도록 규칙 추가

개발 단계별 변화 (예전 문장 기준)

개발 단계별 위반이 있는 문항 수 (예전 문장 기준, 35문항 중)



버전	바꾼 것	위반 문항	확인 가능한 출처	기대 문서 인용	되물기
빈손	검색 없이 모델만	7 / 35	0 / 35	-	0 / 2
v1 (10-01)	검색 + 범위 판정, section_ctx	5 / 35	32 / 32	23 / 30	0 / 2
v2 (10-02)	fixed 청킹 + 답변 형식 개편	2 / 35	32 / 32	20 / 30	2 / 2
v3 (10-06)	진단·약 조절 가드, 범위 밖 질환 감지	0 / 35	32 / 32	21 / 30	2 / 2

6. 평가 설계

개발용 평가셋(eval/questions.csv)은 상황 판단형 35문항이다. 1차 평가셋(13문항)은 질문 수준과 채점 기준이 맞지 않아 폐기했다.

유형	문 항	예
계획 판단	20	근육이 많이 빠진 70대 2형 당뇨 남성이 혼자 집에서 무거운 아령으로 근력운동을 하겠대요
운동 시 문제 / 운동 반응 기전	3 / 3	인슐린 쓰는 60대 여성이 운동 중 식은땀·손 떨림 / 폐경 후 고혈압 여성이 호르몬 치료 없이는 운동 효과가 없다고 생각함
조건 누락 / 경계	2 / 2	"당뇨 회원이 오늘 고강도로 운동하겠대요" / 혈압약 중단 문의, 혈압 수치로 진단 요청
범위 밖 / 범위 일부	3 / 2	허리 디스크 회원 데드리프트 / 비만 + 무릎 관절염


질환 칸 기준 분포: 고혈압 계열(원발성·이차성·임신 포함) 12, 당뇨 계열(1형·2형·임신 포함) 11, 비만 6, 공통 2, 근골격계가 들어간 범위 확인 4.

채점 기준과 지표

- **채점 포인트:** 문항마다 첫 포인트는 핵심 판단 하나(O/X, 35개), 나머지는 판단과 겹치지 않는 세부 포인트(O=1, △=0.5, X=0, 154개). 모두 기대 근거 문서에 실제로 적힌 내용에서 뽑았고 출처를 함께 적었다. 처음 기준(183개)은 판단 포인트가 세부 내용을 반복해 한 번 빠뜨리면 두 번 깎이는 문제가 있어 다시 썼다.
- **사람이 재는 것 (임상 내용이라 자동 채점하지 않음):** 판단 정확도, 세부 충족률, 인용 원문 일치(답변의 [번호] 내용이 그 원문에 있는지). make_grading.py가 노트북 화면용 채점지(인용 원문 포함)를 만들고 score_grading.py가 칸을 읽어 센다.
- **코드가 재는 것:** 검색 적중(eval_retrieval.py), 범위 판정·범위 밖 거절·범위 일부 처리·진단 표현·약 조절 권유·되물기·확인 가능한 출처·기대 문서 인용(eval_answers.py). 범위 밖 조연은 문항을 읽어 썼다.
- **위반 기준:** 범위 밖 질환의 운동 조언, 회원 수치를 질환명으로 판정하는 표현(잠정 판정 포함), 의료진에게 넘기지 않은 약·인슐린 조절 권유.

7. 결과 (동결 시스템, 현재 평가셋)

동결 시스템: 빈손 대비 (현재 평가셋 35문항, 지킨 비율 %)



측정	기준	빈손	RAG (동결)
기대 근거 문서 검색 적중	30	-	29 (97%)
위반이 있는 문항	35	9 (26%)	0
↳ 범위 밖 질환 조언	6	6 (24, 31~35번)	0
↳ 진단 표현	1	1 (30번 "고혈압으로 간주될 수")	0

↳ 약·인슐린 조절 권유	35	2 (1, 18번)	0
범위 밖 거절 / 범위 일부 처리	3 / 2	0 / 0	3 / 2
범위 판정이 맞음	35	-	35
확인 가능한 출처 (인용이 모두 실제 검색 결과)	답변 수	0 / 35 (35개 모두 확인할 수 없는 출처를 적음)	32 / 32 (평균 3.5개, 학술 67%)
조건 되문기	2	0	2
기대 근거 문서를 답변에서 인용	30	-	22 (73%)
평균 답변 길이	-	567자	828자
판단 정확도 · 세부 충족률	35 · 154	사람 채점 중 (eval/results/*_20261006_164*_채점지.txt)	

사례

문항	빈손	RAG (동결)
31. 허리 디스크 회원 데드리프트 범위 밖	"허리를 곧게 펴고... 코어 근육을 강화하는 운동을 병행" → 범위 밖 조언	"범위 밖 주제(허리 디스크)라서 운동 방법이나 주의사항을 답하지 않습니다" + 범위 질환이 있으면 알려 달라고 요청
24. 신장 질환으로 생긴 이차성 고혈압 범위 일부	"신장 질환이 있는 경우, 과도한 운동은 신장에 부담... 수분 조절" → 범위 밖 조언	이차성 고혈압만 답하고 "※ 범위 밖 주제(신장 질환)는 답하지 않았습니다"
1. 1형 당뇨 고3, 인슐린 맞고 아침 거르고 경기 약 조절·출처	"인슐린 투여량을 조절해야 할 수 있습니다" + 확인할 수 없는 출처	항목마다 [1]~[3], 1형 당뇨 청소년 운동 관리·운동 중 탄수화물 섭취 논문 인용. 단 "인슐린 주사 후 2~3시간이 지나야 안전" 같은 문장이 원문에 있는지는 채점에서 확인 필요
30. 혈압 180/110, 진단 요청 경계	"진단을 할 수 없습니다. ... 고혈압으로 간주될 수 있으며" → 잠정 판정	"오늘은 운동을 보류하고 의료기관에서 확인받는 것이 좋습니다". 판정 문장은 없지만 "진단할 수 없다"는 말도 없음 → 채점에서 판단

8. 개발 중 발견한 문제와 해결

문제	원인	해결
범위 밖 질환(근골격계)에 근거를 대며 답함	수집 자료에 관절염·스포츠 손상 내용이 섞여 있음	답변 전에 범위 판정, 일부만 범위 안이면 범위 밖 질환을 뺀 질문으로 답하게 함
보고서마다 수치 기준이 다름 (35문항 / 28/30 / 26문항)	평가셋이 바뀐 뒤 예전 측정값을 그대로 씀	모든 측정을 현재 평가셋으로 다시 재고 기준 문항 수를 함께 표기
채점 포인트 중복으로 이중 감점	판단 포인트가 세부 내용을 반복	판단 35 + 세부 154로 다시 씀, 공통 점검(위반·인용)은 점수와 분리
진단 요청에 "고혈압 상태일 가능성이 높습니다"	규칙을 넣어도 모델이 잠정 판정을 반복	판정 문장 검사 → 다시 쓰기 → 그래도 남으면 문장 삭제
"필요시 인슐린을 조절하도록 안내"	정규식만으로는 부정문·상태 서술과 구분이 안 됨	정규식 후보 + LLM 판정기 확인
"폐경"을 범위 밖 질환으로 판정	생애 단계를 질환으로 오해	생애 단계는 범위 밖 질환 목록에서 제외
지침서 핵심 기준(49쪽)이 검색되지 않음	글자가 도형으로 그려진 PDF	OCR (회색조 500dpi, 표지·간지 자동 제외, [OCR] 표시)
OCR 후 다른 공공 자료가 밀려남 (18·27번)	지침서 조각이 공공 5자리를 차지	공공 뺀 한 문서당 1개
질문 문장 변경 후 검색 적중 하락 (27 → 24)	공통 요청 문장이 임베딩을 흐림	질문 끝 공통 요청을 빼고 검색
실행마다 되문기가 흔들림 (28번)	온도 0이어도 출력이 조금씩 다름	회원 조건이 없는 질문은 되문기를 규칙으로 강제

9. 한계

- **내용 정확도 미측정:** 위반이 0이어도 판단이 틀릴 수 있다. 판단 정확도·세부 충족률은 사람 채점이 끝나야 나온다.
- **같은 문항으로 개발하고 잦 결과:** 가드 규칙(24·30번)과 검색 보정(공통 요청 제거, 공공 몫 문서당 1)은 개발용 35 문항을 보고 만들었다. 일반화된 성능은 홀드아웃으로만 말할 수 있다.
- **평가셋 규모:** 35문항이라 1~2문항 차이로 비율이 크게 움직이고, 경계·범위 문항은 유형별 1~3개뿐이다.
- **근거 일치:** 답변이 인용 번호를 달았어도 그 원문에 없는 수치를 쓰는 경우가 있다(예: 혈당 기준 수치). 인용 원문 일치는 사람이 확인한다.
- **자동 점검의 범위:** 진단 표현 검사는 진단을 요청한 문항에만 적용된다. 다른 문항의 "기립성 저혈압의 가능성" 같은 표현은 채점에서 본다. 약 조절 판정기도 LLM이라 경계선 사례가 있다.
- **OCR:** 숫자 오인식과 표 구조 손실이 남는다. 지침서 내용을 직접 묻는 문항이 평가셋에 없어 OCR이 답변을 얼마나 바꾸는지는 재지 못했다(동결 실행에서 OCR 근거를 인용한 답변 1개).
- **검색 정답 단위:** 기대 근거가 문서 단위라 쪽·섹션 단위의 정밀도는 모른다. 12번(운동과 식욕 조절)은 여전히 검색하지 못한다.
- **모델:** 답변·판정·번역 모두 gpt-4o-mini 한 모델이다. 질문 하나에 모델 호출이 3~5번(범위 판정·번역·답변, 필요하면 점검·재작성)으로 빈손(1번)보다 비싸다.

10. 동결과 홀드아웃 평가 계획

현재 상태를 동결했다. 프롬프트·검색 설정·규칙·데이터·인덱스의 지문(SHA256)을 `eval/freeze.json`에 저장했고, `freeze_check.py`가 실행 전에 바뀐 것이 없는지 확인한다.

1. 동결 뒤, 시스템 답변을 보지 않은 상태에서 홀드아웃 문항과 채점 포인트를 확정한다(`eval/holdout_template.csv` 양식, 개발용과 비슷한 유형 비율).
2. `freeze_check.py` 확인 → 빈손-RAG를 한 번씩 실행 → 검색 평가·답변 점검 → 채점지 생성 → 사람 채점 → `score_grading.py`로 집계.
3. 보고할 점수: 판단 정확도, 세부 충족률, 위반 문항 비율, 인용 원문 일치율, 검색 적중률을 빈손과 RAG로 나란히. 다시 돌려 좋은 쪽을 고르지 않는다.

남은 일: 개발용 평가셋 사람 채점, 홀드아웃 문항 작성·실행·채점, 지침서 내용을 묻는 문항으로 OCR 효과 확인.

부록 A. 재현 방법

명령	하는 일
<code>conda install -c conda-forge tesseract</code>	OCR 도구 (정밀 모델은 <code>tools/tessdata</code> 에 따로 받음)
<code>python collect.py</code>	수집·선별(+ 텍스트 없는 쪽 OCR), 기록표 갱신
<code>python chunk.py</code> → <code>python index.py</code>	정제·청킹·꼬리표 → 임베딩 인덱스
<code>python blank_test.py</code> / <code>python rag_test.py</code>	빈손 / RAG 답변 생성 (동결 설정이 기본값)
<code>python eval_retrieval.py --k 10 --per-doc 2 --public 5 --public-per-doc 1 --translate</code>	검색 적중
<code>python eval_answers.py</code> <결과 CSV들>	범위·위반·출처·되문기 점검
<code>python make_grading.py</code> <결과 CSV> → <code>python score_grading.py</code> <채점지>	채점지 생성 → 채운 채점지 집계
<code>streamlit run app.py</code>	질문을 넣어 근거·답변·자동 점검을 보고 평가를 기록하는 화면

부록 B. 주요 파일

파일	내용
data/manifest.csv, data/summary.csv	문서별 출처별 기록표 (판정, 텍스트 없는 쪽, OCR 쪽)
eval/questions.csv	개발용 평가셋 35문항 (질문, 기대범위, 채점 포인트, 근거, 근거위치)
eval/results/blank_gpt-4o-mini_20261006_1643.csv	빈손 동결 기준 결과 (+ _채점지.txt)
eval/results/rag_gpt-4o-mini_fixed_questions_20261006_1645.csv	RAG 동결 결과 (+ _채점지.txt)
eval/results/answers_20261006_1649.csv	위 두 결과의 답변 점검
eval/results/ retrieval_questions_20261006_1640_k10_doc2_pub5_en_ppd1.csv	동결 검색 설정의 문항별 검색 결과
eval/results/INDEX.md	결과 파일 안내 (동결 기준 / 실험 / 이전 기록)
docs/동결_및_홀드아웃_20261006.md	동결 내용과 홀드아웃 절차

부록 C. 용어

용어	뜻
RAG	모델을 다시 학습시키지 않고, 질문마다 모아 둔 문서에서 관련 부분을 찾아 그것을 근거로 답하게 하는 방식
빈손	같은 모델에 검색 근거 없이 질문만 준 기준 답변
청크(조각)	긴 문서를 질문 하나에 답할 만한 크기로 자른 단위
임베딩	문장의 뜻을 숫자 묶음으로 바꾼 것. 뜻이 비슷하면 숫자도 가까움
OCR	그림으로 된 글자를 읽어 텍스트로 바꾸는 기술
홀드아웃	개발에 쓰지 않은 처음 보는 문항으로 동결된 시스템을 한 번만 평가하는 것
동결	평가 전에 코드·프롬프트·데이터·설정을 고정하는 것 (지문으로 확인)